

# 脳を学ぶ上で重要な数学シリーズ 計算論編

後藤 優仁

2021 年 7 月 3 日

# 目次

0.1	はじめに . . . . .	2
0.2	情報理論 . . . . .	3
0.2.1	エントロピー . . . . .	3
0.2.2	KL 距離 . . . . .	8
0.2.3	条件付きエントロピー . . . . .	10
0.2.4	相互情報量 . . . . .	11
0.2.5	Transfer Entropy . . . . .	12
0.3	信号処理 . . . . .	13
0.3.1	独立成分分析 . . . . .	13

## 0.1 はじめに

さて、この数学シリーズの中でもこの advanced はかなり異質で、筆者が脳神経科学を研究する上で関わっていった様々な (あまり一般的ではない) 議論を展開するために必要になった数学的知識をまとめる場です。筆者は脳活動の非線形ダイナミクスの機能的な役割を研究しています。脳は多数の非線形素子が結合した大自由度の力学系とみなすことができ、多様なダイナミクスを示します。計算論的神経科学の観点で、神経系が示す同期、自発活動、誘発活動ダイナミクス、ノイズ誘発同期、... といった様々な現象を捉え、その情報処理メカニズムの解明を試みています。

こうした作業には、信号処理は勿論、非線形ダイナミクス (つまり力学系)、情報理論、複雑系、機械学習... 多種多様な数学的、理論的知識が求められます。この勉強については終わりがなく、本当に役に立つのかも分かりません。ただ確実に言えるのは、

「○○をやっている時の脳は△△領域で～～ms 後に  $\times$  Hz の波が同期している！！」

なんてことだけ見ても、脳を理解する事は出来ないということです。その活動が何故大事なのか、その活動を通してどんな処理をしているのか... こうしたところまで理解してこそその科学だと、筆者含め計算論的神経科学者たちは考えています。

実験的にデータを集めるだけでは理解に至らず、その背景で何が行われているのか、どんな表現がなされているのか。そんなところまで考えないとだよね、というスタンスです。その必要性が分からん、そんなに大事だろうか。そう思う人はユニークな思考実験的論文があるので是非読んでみてください [1][2]。何をもって脳の理解とするか？

この間に答えるのが、有名なマーの3レベルという概念？お話？ [3] です。

- 計算理論
- 表現とアルゴリズム
- ハードウェアによる実装

この3段階を踏み、相互に対応付ける事が脳の理解に大切だ、とする話です。計算理論は、我々が脳を使ってどんな「計算」を行っているのか、行っているべきなのか、といった議論。自由エネルギー原理だとかの話、すなわち脳が採用している戦略を考える所です。ハードウェアによる実装は、多くの神経科学者がやっているように脳のどの部分でどんな活動が起きていてといった解剖学・生理学的知見。最後に表現とアルゴリズムは、ハードウェアの実装を使っていかに計算理論で提案された処理を実行するのか、になります。

彼に言わせれば、これまで主流の神経科学はハードウェアの実装ばかりだったわけですね。計算理論と表現に関する議論は、無論ありましたがあまり活発ではなかった。

ここから先、どう考えるかは個人の自由だと思います。計算理論や表現についても考えていこうとする

か、そんなに色々手を出しても回収しきれないと見切りをつけるか、あるいは他の人が結び付けてくれる事を期待して実験データを提供するに集中するのか...

筆者は、計算理論と実装を結ぶ、表現の研究者になりたいと考えた次第です。一番勉強する事が多いような気もしますが、楽しんでやっていきます。

長くなりましたが、本書はそんなモチベーションのもと、計算理論やアルゴリズムについて学習したことをまとめていくものにします。なので神経に本当に役立つのか、理解が正しいのか、様々な問題があると思いますが、まあ教科書ではなく筆者のノートだと思って見てください。結構やってみると楽しいです。また本稿はその性質上、随所で本や論文を引用しながら議論を展開していきます。筆者の拙い理解での説明では不十分だったり不適切だったりすることも少なくないはずなので、気になるところは適宜参照してください。

## 0.2 情報理論

近年は神経科学に情報理論の議論を輸入するのが流行りになっている気がします。脳波の解析もだし、情報処理の理論もそうだし、いろんなところで見るのでとりあえず勉強。関係する研究は以下とか

- 自由エネルギー原理 [4]
- Phase Amplitude Coupling の評価. [5]
- 相互情報量
- トランスファーエントロピー

\*まだちゃんと引っ張ってきてない

### 0.2.1 エントロピー

はじめにエントロピーの考え方を導入しましょう。まずは離散確率変数  $x$  を考えます。観測者がこの変数に対するある値を観測したとき、どれだけの情報量、surprise を得られるのか。これを考える概念がエントロピーです。

直観的に、起きそうもない事象が得られたら情報量は大きいし、その逆も然りですよね。宝くじで1等が当たるのはめちゃくちゃびっくりする、つまり情報量大きいけど、参加賞的なのもらっても何も思いません。つまり情報量は確率分布  $p(x)$  に依存していて、その値によって定まる単調な関数  $h(x)$  といえます。

また、2つの事象  $x, y$  を考えたとき、これらが独立なら両方を観測したときの情報量は別個に観測したときの情報量の和と等しい(式1) はずです。宝くじが当たる事による surprise によって、帰りに頭に雷が落ちてくる事によって生じる surprise が小さくみたいになることはないですよ？あるかもな。ないっ

て事にしてください.

よって以下の式 (1) が成り立ちます.

$$h(x, y) = h(x) + h(y) \quad (1)$$

次に, これらの事象の同時確率についても単純に積で求められます (式 2). 宝くじが当たり, かつ頭に雷が降ってくる確率です.

$$p(x, y) = p(x)p(y) \quad (2)$$

もし式 (1, 2) が分からないようなら基本的な確率が出来てないので, statistics.pdf で勉強してみてください.

さて, ここはちょっとテクいです.

この二つの関係から,  $x$  と  $y$  の確率をかける操作をしたものに対して何らかの処理をしたものが, 何らかの処理をした  $x$  と  $y$  の和になっているので, 関数  $h(\cdot)$  は対数をとっている事が分かり (ほら, 掛け算って対数だと足し算じゃん?),

$$h(x) = -\log p(x) \quad (3)$$

がいえます.  $\log(x)$  は単調増加で, 確率  $p(x)$  は常に 0 から 1 の範囲をとるため,  $h(x)$  の値を常に正にするため符号を反転させている事に注意です. ここで対数の底に 2 を採用するのが情報理論での一般の使い方, その場合は  $h(x)$  の単位は bit になるようです.

これを使って, 信号のサイズ, 情報量 (bit) を算出してるわけですね. あとデータの圧縮なんかにも関係すると思いますがそこまでは知らないし触れませんか触れられません.

次に, この値を分布全体に適用する事を考えます. つまり, 確率分布そのものが与える情報量です. その指標として, 確率変数  $x$  の分布  $p(x)$  に関して  $h(x) = -\log p(x)$  の期待値をとることで, 情報量の平均を定義します. 確率変数の期待値の一般的な計算です. これも分からなければやはり statistics に行ってください.

$$H[x] = -\sum_x p(x) \log p(x) \quad (4)$$

式 (4) に定義する量をシャノンエントロピーといいます [6]. 意外と簡単ですね. もっと難しいと思ってました.

ついでにこれを連続変数にすると微分エントロピー (式 5) が求まります.

$$H[x] = -\int p(x) \log p(x) dx \quad (5)$$

言うまでもないと思いますが、 $\sum_x p(x)$  も  $\int p(x)$  も 1 です。

さて、次に当然浮かぶ疑問は、どんな確率分布だとどんなエントロピーが算出されるのか、です。

ちゃんと数学的に証明することも出来るっぽいけど面倒だしそこにあんまり興味ないので、simulation してみます。

とりあえず一様分布で確認してみます。0.1 から 1 の値をとる、サンプル数 10 の一様分布 (図 0.2.1) のエントロピーを算出します (コード 1)。

Listing 1: エントロピーの計算

```
1 x = [0.1:0.1:1];  
2 px = zeros(1,10)+0.1;  
3 H = - sum(x .* log(px));
```




図 1: 0.1 が 10 個の一様分布

エントロピーは 12.7 でした。次に、同じ一様分布でもサンプル数が多いとどうなるのか試します。先ほどと同じ条件の、100 個のデータ (図 0.2.1) です。




図 2: 0.01 が 100 この一様分布

エントロピーは 232.5. 大きくなりましたね. データ数に応じてエントロピー自体は大きくなるぽいです.  
次に山を持たせた分布で見えます.




図 3: 適当につくった山あり分布

エントロピーは 22.3. 一様分布に比べるとかなり小さいです. 本当はもっと山の位置動かしたり急峻にさせてみたりと比較したいですが, 飽きたので結論. (離散) エントロピーは確率分布  $p(x)$  が一様分布に近づく程大きくなり, 一様分布の時に最大になります.  $x * \log(x)$  なのでもあ, 考えればそうかなって感じ. 証明は結構めんどくさいぽいです.

この性質から, 状態の予測が困難であるほどエントロピーが高い事になるので, 不確かさ (Uncertainty) の指標として用いられる事が多いですね.

ちなみに微分エントロピーの場合はガウス分布が最もエントロピー高いようです.

他にも見れる性質があって, まず  $p(x)$  が 0 は困ります.  $\log$  にかけた時に計算がこわれるので. 無限に吹っ飛びます.

あと, 一様分布の比較から分かるようにデータ数が多いほどエントロピーも増大するぽいですね. これもまあ普通に総和とってるんだから当たり前か?



## 0.2.2 KL 距離

さて、このエントロピーがどんな事に使えるのか考えていきます。エントロピーは分布の特徴を表す量になっていたわけなので、これを使うと二つの分布の比較、なんてことも出来ることになります。直観的には、全く同じ特徴の分布同士ならそのエントロピーに差はないし、違う分布なら差がある、という感じです。

式にしてみましょう。まず、微分エントロピー  $(-\int p(x)\log p(x))$  は確率変数  $x$  の分布  $p(x)$  の元での期待値でした。なら、ここで新しい分布  $q(x)$  を考えたとき、仮にこの分布が同一 ( $p(x) = q(x)$ ) であれば、

$$\int p(x)\log q(x)dx - \int p(x)\log p(x)dx = 0 \quad (6)$$

が成り立つ事になります。同じ分布の元で考えた同じ確率変数の期待値だから、当たり前です。分布  $p(x)$  の元で見た  $q(x)$  の期待値が、分布  $p(x)$  の元で見た  $p(x)$  の期待値と等しい、ということです。逆にこの分布が異なるものであるほど、この計算の結果は大きな値を取る事になります。

てなわけで、この量をちゃんと正負の調整した上で、「分布  $p(x), q(x)$  の相対エントロピー、あるいはカルバック-ライブラー距離、またはカルバックライブラーダイバージェンス」として以下の式で定義します [6]。

$$\mathbb{D}_{KL}(p||q) = - \int p(x)\log q(x)dx - (- \int p(x)\log p(x)dx) \quad (7)$$

$$= - \int p(x)\log \frac{q(x)}{p(x)}dx \quad (8)$$

一寸ややこしく見えますが、基本的には式 (6) を  $\log$  について整理しただけです。簡単ですね。

KL 距離の性質ですが、まず  $\mathbb{D}_{KL}(p||q) \geq 0$  です。距離だし。等号が成り立つのは分布  $p(x), q(x)$  が等しいときのみです。

それから  $\mathbb{D}_{KL}(p||q) \neq \mathbb{D}_{KL}(q||p)$  なことにも気を付けてください。分布  $p(x)$  の元で見た  $q(x)$  の期待値と、分布  $q(x)$  の元で見た  $p(x)$  の期待値とは別物ですからね。

それから、対数なので KLD は以下のような表記のこともあります。一緒です。  $\log$  の計算の性質を思い出してください。割り算は引き算です (?)

$$\mathbb{D}_{KL}(p||q) = \int p(x)\log \frac{p(x)}{q(x)}dx \quad (9)$$

留意してください。

あと、KL “距離” と日本語で呼んでいますが厳密には距離じゃないので注意が必要です。というのも、KLD は以下に示す距離の公理 [7] を満たしていないからです。

#### 距離の公理

2 点  $A, B$  が与えられたとき、実数  $d(A, B)$  を与える規則で、次の性質を満たすものを距離という。

- $d(A, B) \geq 0$
- $d(A, B) = 0 \leftrightarrow A = B$
- $d(A, B) = d(B, A)$
- $d(A, B) + d(B, C) \geq d(A, C)$

このうち、KLD が満たしていないのは为什么呢？

そう、3 つめの対称性ですね！ $\mathbb{D}_{KL}(p||q) \neq \mathbb{D}_{KL}(q||p)$  でした。

あと 4 つ目、三角不等式も怪しいと思うんですよね。呼んでた資料とかでは特に対称性のとこだけネチネチと言われてましたが、三角不等式はどうなのでしょう？

直観的には微妙だと思ってて、だから KLD の値を単純に比較したりだとかの議論は出来ない気がする。

じゃあ KLD はどう使うんだよって話ですが、最小化したい量として導入してるのが多い気がします。つまり、予測分布を真の分布に近づけたい、だとかですね。この時に最小化する、分布と分布との距離として使われる量です。

あとは、一様分布と得られたデータ分布との距離を測る、なんて使い方もありました [5]。この場合は正規化的なのして、 $\mathbb{D}_{KL}(P||U)$  (where  $U$  is the uniform dist) を 0-1 の値にして使っていましたね。

いまのとこ個人的に分からないのは、 $\mathbb{D}_{KL}(A||B)$  と  $\mathbb{D}_{KL}(C||D)$  の値を比較した議論 (たとえば、 $A-B$  は  $C-D$  の 3 倍離れている！) なんてのは出来るのかなってところです。

ユークリッドなら自明に出来ると思うんですけど、これだとなんか出来ない気がする。三角不等式も怪しいし。

どうなのでしょう？今後の課題になってます。

余談ですが、式 (7) の右辺第一項、 $-\int p(x) \log q(x) dx$  は交差エントロピー  $H(p, q)$  とも言います。分布  $p(x)$  の元で見た  $q(x)$  の期待値なので、 $p(x)$  の分布を想定したとき、 $q(x)$  がどれだけ予測しにくいのかも捉えられます。

これだけでも、交差エントロピー  $H(p, q)$  は正解値と推定値の比較なんかの用途で使えるようです。

じゃあ KLD と何が違うのか、というと、ここからは個人的な予想ですが...

問題なのは  $p(x)$  自体の分布が既にもってる情報量、つまり  $H(p)$  なんだと思います。

交差エントロピーは計算式をみれば分かるように、 $p(x)$  自体のエントロピーの影響を受けた数値になってしまうため、なんというか「どれくらい外れているか」の指標に使うにはフェアじゃない気がします。

なので交差エントロピーの値から、 $p(x)$  自体が持っているエントロピーの値を差し引いた量が知りたいわけですね。そうすると式 (7) は

$$\mathbb{D}_{KL}(p||q) = H(p, q) - H(p) \quad (10)$$

とも捉えられますね。あってるのかな？

## 他の分布間距離

確率分布同士の距離を測る指標は  $\mathbb{D}_{KL}$  だけでなく、他にも以下のようなものがあるっぽいです [8]。

$$\chi^2(Q||P) := \sum_{i=1}^k \frac{(p_i - q_i)^2}{p_i} \quad \chi^2 \text{ 統計量} \quad (11)$$

$$L_1(Q||P) := \int |Q(x) - P(x)| dx \quad L_1 \text{ ノルム} \quad (12)$$

$$L_2(Q||P) := \int \{Q(x) - P(x)\}^2 dx \quad L_2 \text{ ノルム} \quad (13)$$

$$I_K(Q||P) := \int \{\sqrt{Q(x)} - \sqrt{P(x)}\}^2 dx \quad \text{ヘリンジャー距離} \quad (14)$$

$$\mathbb{D}(Q||P) := \int f\left(\frac{Q(x)}{P(x)}\right) Q(x) dx \quad \text{f-ダイバージェンス} \quad (15)$$

$$I_\lambda(Q||P) := \int \left\{ \left( \frac{Q(x)}{P(x)} \right)^\lambda - 1 \right\} Q(x) dx \quad \text{一般化情報量} \quad (16)$$

$$\mathbb{D}_{KL}(Q||P) := \int \log\left(\frac{Q(x)}{P(x)}\right) Q(x) dx \quad \text{KL 情報量} \quad (17)$$

どれがどんな時にどう使われるとかは調べてないです、でもこれでいくと上 3 つはよく見る気がする。でもまあ全体的に似てるポイですね。なんとなく哲学というか考え方はどれも似たりよったりな気がします。

### 0.2.3 条件付きエントロピー

エントロピーは式 (5) に示す量でしたが、これを条件付き確率  $p(x, y)$  に拡張して考えます。今  $x$  が既知である場合、同時分布  $p(x, y)$  について  $y$  を特定するための情報は  $-\log p(y|x)$  なので（これはいいよね？条件付き確率です）、その合計は

$$H(y|x) = - \iint p(y, x) \log p(y|x) dy dx \quad (18)$$

で表され、これは条件付きエントロピーといいます [6][8]。さらにこれを使えば

$$H(x, y) = H(y|x) + H(x) \quad (19)$$

と書けますね！エントロピーは対数なので、確率の乗法を意味しています。つまり  $x$  と  $y$  の同時分布を記述する情報量は、 $x$  単体の情報量と  $x$  が与えられた元での  $y$  の情報量との和になるわけですね。

## 0.2.4 相互情報量

KL 距離は分布と分布の距離を測れる便利な指標でした。

これを使った、これまた便利そうな指標の一つが相互情報量です。二つの変数  $x, y$  を考えて、こいつらの同時分布  $p(x, y)$  が得られたとします。この時、この変数 2 人の間にどんな関係があるのか確認したくなりますよね。他人なのか、それとも親密な関係なのか... まあつまり独立かどうかです。

さて、KL 距離はこの独立性の検証的な使い方が可能で、それがまさに相互情報量の計算です。式 (20) を見た方が早いでしょう [8]。

$$MI(x, y) = H(x) + H(y) - H(x, y) \quad (20)$$

$x$  と  $y$  が独立であった場合の同時確率の情報量と独立でないときの情報量の離れ具合を見るわけですね。例のごとく対数なので、要は  $p(x)p(y)$  と  $p(x, y)$  です。これは KLD を使えば式 (21) のように表せます。

$$MI(x, y) := \mathbb{D}_{KL}(p(x, y) || p(x)p(y)) = - \iint p(x, y) \log \frac{p(x)p(y)}{p(x, y)} dx dy \quad (21)$$

あら簡単。変数  $x, y$  の同時分布と周辺分布積との KLD を見るだけです。KLD なので、両者が同じ、つまり  $x$  と  $y$  が独立である時に限って 0 になる量ってわけですね。

てことは、 $x$  と  $y$  がずぶずぶの関係であるほど値が大きくなるわけだから、 $y$  の値を知る事によって  $x$  の不確実性が減った度合を表すと言えそうです [6]。

KLD 同様、符号反転で以下の表記 (式 22) もあります。

$$MI(x, y) := \iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy \quad (22)$$

式 (21) を見れば分かりますが、相互情報量は対称性を持っており、 $MI(x, y) = MI(y, x)$  です。なのでどっちがどっちにどの程度依存しているみたいな議論までは出来ません。

## 0.2.5 Transfer Entropy

相互情報量は2つの確率変数間の相互依存度のような指標でしたが、どっちがどっちに依存している関係なのか、みたいな因果性まで見れたらカッコいいですね。そう、それが Transfer Entropy です。

え？いや例えば領域 A の活動が元に領域 B の活動が起きてるとか言いたいじゃないですか。

少し話はそれますが、やはり我々神経科学者にとって 21 世紀入ってからの大きな問題の一つが因果性の検証だと思うんですよね。いろんなデータが実験的に得られているけど、基本的には相関でしかなくて。「So what?」なんですよ。なので電気刺激や磁気刺激、古いけど破壊法だったりオプトジェネティクス、最近ではニューロフィードバックなんて手法を使って、追加実験的に因果性の検証をしているのが流行りになっています。

でも面倒なので、どうせなら計測した脳活動だけで因果関係まで言えたら嬉しいよねってモチベーションで考えられるのが effective connectivity とかで、Transfer entropy はまさに Effective connectivity の一種です。

閑話休題。

本題ですが、Transfer Entropy の基本的な考え方はこんな感じっぼいです。まず、因果といってもあくまで情報理論的な観点で見た因果「y の結果、x が起きた」です。ちょっと緩いわけですね。実際、まじな因果の検証とか無理では？とも思いますが。

この「y の結果～」という表現からも分かるように、概念の背景に時間軸がひそんでいます。相互情報量はある同時刻の活動のみを比較するような処理をしていましたが、ここに経時的な変化の考慮も踏まえ、経時的な変化における確率変数同士の依存度を見ていく必要があります。

大丈夫ですかね？ここまでは前提です。

ではコアになる考え方ですが、もし仮に y の結果として x が起きているのであれば、x 単体の時系列を使った  $x_{t+1}$  の予測よりは x と y の値を使った  $x_{t+1}$  の方が精度が高いですね。式にするとこう。

$$\frac{p(x_{t+1}|\mathbf{x}_t)}{p(x_{t+1}|\mathbf{x}_t, \mathbf{y}_t)}$$

こいつらの値を比較したとき、 $x_{t+1}$  の値が  $\mathbf{y}_t$  に全く依存していないのであれば、両者に差はなく等しくなるはずですね。

ふう。

ここまで来たらあとは相互情報量の時と一緒にです。KLD を使って

$$T_{y \rightarrow x} := \mathbb{D}_{KL}(p(x_{t+1}|\mathbf{x}_t, \mathbf{y}_t) || p(x_{t+1}|\mathbf{x}_t)) = - \sum p(x_{t+1}|\mathbf{x}_t, \mathbf{y}_t) \log \frac{p(x_{t+1}|\mathbf{x}_t)}{p(x_{t+1}|\mathbf{x}_t, \mathbf{y}_t)} \quad (23)$$

で定義される量を、 $y$  から  $x$  への Transfer entropy とします。例によって符号反転で

$$T_{y \rightarrow x} = \sum p(x_{t+1} | \mathbf{x}_t, \mathbf{y}_t) \log \frac{p(x_{t+1} | \mathbf{x}_t, \mathbf{y}_t)}{p(x_{t+1} | \mathbf{x}_t)} \quad (24)$$

とも表します。この量は  $\mathbf{y}$  を知る事によって減少した  $x_{t+1}$  の不確かさです。相互情報量とは似ているようで異なります。

また例のごとく式から分かるように  $T_{y \rightarrow x} \neq T_{x \rightarrow y}$  です。このことから、Transfer Entropy には向きが含まれており、したがって因果性の議論に使えるわけですね [9]。

因果性といえば他に有名なのは Granger Causality ですが、こいつらの比較はまた今度気が向いたらやってみます。

## 0.3 信号処理

信号処理の基本は Analysis.pdf の方に載せていますが、理解が必須ではない、というか少し難しいものはこちらにあげていきます。

### 0.3.1 独立成分分析

Independent Component Analysis (ICA) と呼ばれる多変量解析の手法です。だいたい 90 年代頃に確立されました。まずどういったものかと言うと、観測された信号を独立な複数の信号の線形な重ね合わせとして再表現するものです。

といってもよくわからないと思うので、我々も実は日頃から ICA をやっていますよという話からしましょう。皆さん毎日夜には駅前の居酒屋やバーで楽しくお酒を嗜んでいる事かと思いますが、実はこの時我々の脳は独立成分分析をしているのです。

飲み屋では多くの人間が同時に声を発し、食器の音やどこかのコールの音、厨房の音と無数の音が同時に我々の耳=脳に送られてきます。しかしどういうわけか、その音がどこの誰の声か、厨房の音なのか食器の音なのか判断できますよね。つまり、与えられた音の時系列データ (これは一つのデータに重ねられて聴こえてる) を複数の信号源に分解している、そう、独立成分分析をしているわけです。

我々は特に意識せずとも当たり前のように出来るこの作業ですが、実は PC にやらせるととんでもなく難しかったのです。それをどうにか実現しましょうという事で出来たのが現在の ICA です。

脳波の研究に何の役に立つのかですが、端的に言えばノイズの除去や脳活動の特徴抽出です。脳波はだいたい 64ch の電極を使って計測するわけですが、そこには残念ながら眼球運動由来の電位や筋肉の電位など、脳波ではない成分も乗ってしまっています。これらは脳波に比べて電位も大きいので、脳波の解析の際に邪魔以外のなにものでもなく、親の仇のように憎むべき存在です。

もう分かるかと思いますが、“脳波” 信号を分解し、真の脳波信号と眼電、筋電、などに分解してあげるのに使えるのが独立成分分析です。実用では、こうして分解したデータのうち眼電や筋電由来と思わ

れる成分だけ取り除いてあげれば綺麗に脳波だけ見れるわけですね。すくなくとも目的はそんなとこです。

長くなりましたが日本語はこれくらいにして、早速数理に入りましょう。まず元の時系列信号を  $\mathbf{x}(t)$  とします。これが、初めに仮定より線形な ( $N \geq 2$ ) 個の信号源 ( $\mathbf{s}(t) = [s_1(t), s_2(t), \dots, s_N(t)]$ ) からの信号の重ね合わせによって  $N$  個のセンサに観測されているとします。ここで信号源とセンサーの個数が一緒なのに違和感を覚える人もいると思いますが、とりあえず置いてください。実際脳波の ICA も基本的にチャンネル数と同じ数に分解します。するとこの関係は

$$\mathbf{x}(t) = \mathbf{A}\mathbf{s}(t)^T \quad (25)$$

と表せます。ここで  $\mathbf{A}$  は  $N \times N$  の係数行列で、 $a_{ij}$  は  $i$  番目のセンサで観測される  $j$  番目の信号源からの信号の係数です。この値が大きいのは信号源の影響を強く受け、小さいのはあまり受けていない事を意味します。

ではここで、今回の問題で求めたいのは  $\mathbf{s}(t)$  ですよね。なので  $\mathbf{s}'(t)$  的な行列として  $\mathbf{y}(t)$  を定義し、

$$\mathbf{y}(t) = \mathbf{W}\mathbf{x}(t) \quad (26)$$

という式をたてます。実数の分離行列  $\mathbf{W}$  を元信号にかけて  $\mathbf{y}(t) = [y_1(t), y_2(t), \dots, y_N(t)]$  で表される分離信号に分解する事を考えます。分離行列も  $N \times N$  の成分をもっていて、それぞれのセンサの値をどれだけ反映させて分離信号を生成するのか、を分離信号の数だけ行います。この  $\mathbf{y}(t)$  が綺麗に独立するように  $\mathbf{W}$  を更新していくのが独立成分分析の手順です。

ではその独立性をどう表すか、というところですが、 $\mathbb{D}_{KL}$  を使います。正確には相互情報量です。相互情報量は、複数の変数があったときにその同時分布と周辺分布の積との間の KL 距離を測るものでしたね。両者が全く同じ分布である時、0 になるものだったので、相互情報量が 0 になる時は変数が全て独立である、という事を表せるのでした。これを使います。

$$p(\mathbf{y}) = p(y_1, y_2, \dots, y_N) \quad \text{同時分布} \quad (27)$$

$$p(\mathbf{y}) = \prod_{i=1}^N p(y_i) \quad \text{周辺分布} \quad (28)$$

こいつらの KL 距離が相互情報量だから

$$\mathbb{D}_{KL}(\mathbf{y}) = \int p(\mathbf{y}) \log \frac{p(\mathbf{y})}{\prod_{i=1}^N p(y_i)} d\mathbf{y} \quad (29)$$

と表せます。この時、式 (29) が 0 になるのは  $p(y_1, y_2, \dots, y_N) = \prod_{i=1}^N p(y_i)$  が成り立つ、つまり独立な信号源として仮定した  $\mathbf{y}$  がちゃんと独立である時になります。よって最小化しましょう。

$$\begin{aligned}
\hat{\mathbf{W}} &= \arg \min_{\mathbf{W}} \mathbb{D}_{KL}(\mathbf{y}|\mathbf{W}) \\
&= \arg \min_{\mathbf{W}} \int p(\mathbf{y}|\mathbf{W}) \log \frac{p(\mathbf{y}|\mathbf{W})}{\prod_{i=1}^N p(y_i|\mathbf{W})} d\mathbf{y}
\end{aligned} \tag{30}$$

式 (29) が 0 になるように分離行列  $\mathbf{W}$  を逐次更新していけばいいわけですね。最小化する逐次更新の仕方はいくつかあって、最有力?なのが勾配法を用いるものです。勾配法についてまだちゃんと勉強できていないので今は式だけ。

$$\mathbf{W} \leftarrow \mathbf{W} - \eta \mathbf{E}[\phi(\mathbf{y})\mathbf{y}^T - I] \mathbf{W}^{-T} \tag{31}$$

この更新式 (30) に従って評価式 (29) を更新していけば相互情報量を最小化できて、無事に元の  $\mathbf{x}(t)$  を独立成分  $\mathbf{y}(t)$  を取り出すことが出来るわけですね。正直最後だけまだ分かん。でも最小化したいてのは分かるのでとりあえずヨシ！



## 関連図書

- [1] Lazepnik, Y. (2002). “Can a biologist fix a radio?-Or, what I learned while studying apoptosis.” *Cancer Cell*, 2(3), 179-182.
- [2] Jonas, Eric, and Konrad Paul Kording. (2017). ”Could a neuroscientist understand a microprocessor?.” *PLoS computational biology* 13.1.
- [3] Marr. (1982). “Vision.”
- [4] Friston, K. (2010). “The free-energy principle: A unified brain theory?” *Nature Reviews Neuroscience*. Volume 11, Issue 2, February 2010, 127-138
- [5] Adriano B. L. Tort, et al. (2010). “Measuring Phase-Amplitude Coupling Between Neuronal Oscillations of Different Frequencies” *Journal of Neurophysiology* 104:1195-1210.
- [6] Christopher M. Bishop. (2006). “Pattern Recognition and Machine Learning”
- [7] Wikipedia
- [8] yumaloo. “Kullback-Leibler Divergence についてまとめる”  
<https://yul.hatenablog.com/entry/2019/01/07/152738>
- [9] Katunori Kitano. “Transfer entropy を用いた神経回路の解析” *Annual Review 神経* 2017 I. Basic Neuroscience.